



教育经历

- 华东理工大学 · 计算机科学与技术 · 硕士 2024 - 2027
 - 荣誉: 国家励志奖学金、校级优秀奖学金、蓝桥杯大学A组C/C++省二等奖。
 - 核心课程: 操作系统、计算机网络、数据结构、UCB CS61A/B。
- 某高校 · 人工智能 · 本科 2020 - 2024
 - 荣誉: 国家励志奖学金、校级优秀奖学金、蓝桥杯大学A组C/C++省二等奖。

实习经历

- 某初创小厂 · 具身语音 Agent / AI Agent 实习生 2026.04 - 至今
 - 项目目标: 面向多模态设备 (如 飞飞、generic 摄像头、麦克风、PrimeBot、Vbot) 打造统一语音入口, 让用户可以用自然语言完成设备控制、视觉理解与输出, 支持本地/云端多模态协同。
 - 技术方案: 基于 Python、ROS2、FastAPI、LiveKit 接入 Vbot/PrimeBot 硬件, 打通原生麦克风、摄像头、扬声器、表情/动作控制与 Agent 音频输出。引入 Langfuse 做观测, 结合 ASR、LLM、TTS 分段耗时统计; 通过 ASR+LLM+TTS 首评将延迟从 3.8s 优化至 2.4s, 大模型首 token 响应从 2.49s 降至 1.15s。
 - 核心突破: 设计 Vbot supervised patrol 安全巡逻能力, 复用原厂自主运动栈, 使用 Gemma4:e4b VLM 判断是否到达目标、是否应停下或继续探索; 基于累计近 3,000 条样本评测复杂盘, 准确率达 84.0%, 平均决策延迟 0.88s。
- 某初创小厂 · AI Agent 实习生 2025.04 - 2026.04
 - 职责: 参与 AI Agent 与大模型应用落地, 推动 XiaoBa-CLI / Agent Runtime、企业 IM 智能助手、长期记忆系统与 AI 文档平台的设计和开发。
 - 工作内容: 基于 XiaoBa-CLI / Agent Runtime, 与 3 家合作企业落地生物医药、教育、工程咨询三类垂直行业 IM 智能助手, 提升信息检索与协同效率。

项目经历

- 01 XiaoBa-CLI | Local Coding Agent Runtime & Evaluation Harness 2026.01 - 至今
 - 技术栈: TypeScript、Python、Electron、Node.js | GitHub:
 - 执行底座 (Runtime): 围绕 Agent Runtime 搭建多轮状态机与统一的 ToolManager, 集成 read/write/edit/glob/grep/shell 等本地工具, 支持角色隔离、会话管理、模型切换、工具调度、异常恢复与产物追踪, 在本地 coding 与企业 IM 等场景中稳定支持长流程。多工具任务。
 - 评测与回放: 自研 trace 体系, 记录用户输入、工具调用、文件变更、异常处理与最终交付; 提供 playback、trace 抽取、replay case、runtime 级别的 fresh trace, 并支持 verifier / scorecard 做周期性回归。
 - 协作层: 实现 subagent 任务调度与通信, 支持父子会话隔离、步骤执行、状态查询、日志追踪与结果回流; 面向长任务拆解和多 Agent 协同场景。
 - 能力扩展: Runtime / Role / Skill 三层设计。Runtime 负责统一调度与执行; Role 描述角色边界与系统提示词; Skill 通过 Skill.md + frontmatter 完成注册、加载与版本管理, 支持热插拔与权限控制。
 - 产品落地: 打通飞书、微信、CatsCompany 三类消息入口; Electron 封装桌面端并提供可视化 Dashboard; 目前已经服务 3 家企业小规模部署, 覆盖约 30-60 名内部用户, 并沉淀 3 类 Roles 和 20+ Skills。
- 02 GauzMem | Long-term Memory & Hybrid Retrieval System 2025.11 - 2026.02
 - 技术栈: Python、Neo4j、Qdrant、MySQL、DashScope | GitHub:
 - 设计思路: 将长期记忆分为事实 (Facts) 与主题 (Topics) 两层, 事实用于保存事件、人物、时间等客观信息, 主题聚合相关上下文, 形成可扩展的知识图谱与向量索引联合检索。
 - 架构亮点: 基于主题聚类降低长对话噪声, 通过时序关系与 8 类关系 (前后邻接、因果、相似等) 增强检索质量; 混合检索链路支持跨轮事实追踪、多跳问答与因果链推理。
 - 效果指标: 在 LoCoMo 长期记忆 benchmark 上 LLM Judge 准确率 86.75%, 其中 Multi-hop 89.4%、Single-hop 87.9%。
- 03 Vibe Writing Platform | AI 文档写作平台 2025.05 - 2025.11
 - 技术栈: Python、FastAPI、MySQL、MinIO、Monaco Editor、MinerU、RAG、OpenRouter
 - 项目成果: 面向长文档生成存在结构不稳定、内容不可追溯与后编辑成本高的问题, 搭建多模块 AI 文档写作平台, 覆盖对话、资料管理、模板生成与后编辑全流程。
 - 核心能力: 支持 Agent 结合资料/模板 RAG 生成 Review · Editor 后编辑; 基于 Plan and Execute 思想构建工作流: Planner 解析模板生成章节规划 → Executor 负责分章节并行写作 → Review 负责查重与语义一致性审查。
 - 工具集成: 集成 MinerU + RAG 建立可追溯资料链路, 并基于 Monaco Editor 支持选中文本 AI 改写、局部扩写、语气调整与自然语言生成图表。

专业技能

- 编程与工程: Python、Java、TypeScript、Node.js, 熟悉 Java 后端, 有 FastAPI 与 Express/WebSocket 接口开发经验。
- LLM 应用开发: Prompt 设计、工具调用编排、上下文管理、Token 成本控制与多模型容错切换。
- Agent 系统开发: 熟悉 Agent Runtime、subagent 调度、Agent2Agent 协作、Role/Skill 机制, 多阶段任务执行与具身语音 Agent 联调。
- RAG 与记忆系统: 具备向量检索、知识图谱、长期记忆、文档解析与可追溯生成相关项目经验。